

决策树构建 - 信息增益计算（详细版）

基于以下数据集，逐层计算特征的信息增益，最终构建决策树：

序号	年龄	服务时间	月消费	投诉次数	非保险费	续签
1	青年	短	低	0	基础	不续签
2	青年	中	中	1	基础	不续签
3	中年	长	高	0	高级	续签
4	老年	长	中	0	高级	续签
5	老年	长	低	≥2	基础	不续签
6	中年	中	高	1	高级	续签
7	青年	短	中	0	基础	不续签
8	中年	长	高	0	基础	续签
9	老年	中	中	1	高级	续签
10	青年	长	高	≥2	高级	不续签
11	中年	短	高	0	高级	续签
12	老年	短	低	0	基础	不续签
13	青年	中	高	1	高级	续签
14	中年	中	中	0	基础	不续签
15	老年	长	高	≥2	高级	不续签
16	青年	短	低	0	基础	不续签
17	中年	中	高	0	基础	续签
18	老年	中	高	1	高级	续签

序号	年龄	服务时间	月消费	投诉次数	非保险费	续签
19	青年	长	中	0	高级	续签
20	中年	长	中	≥2	基础	不续签

第 1 层：根节点（整个数据集）

1. 计算根节点的信息熵 $Entropy(S)$

总样本数 $N = 20$

续签样本数 $N_{续签} = 9$ （行 3、4、6、8、9、11、13、18、19）

不续签样本数 $N_{不续签} = 11$ （剩余行）

信息熵公式：

$$Entropy(S) = - \sum_{i=1}^n p_i \log_2(p_i)$$

其中 p_i 是类别 i 的概率（样本占比）

代入计算：

$$Entropy(S) = - \left(\frac{9}{20} \log_2 \left(\frac{9}{20} \right) + \frac{11}{20} \log_2 \left(\frac{11}{20} \right) \right)$$

分步计算：

$$\frac{9}{20} = 0.45, \log_2(0.45) \approx -1.152, \text{ 所以 } 0.45 \times (-1.152) \approx -0.5184$$

$$\frac{11}{20} = 0.55, \log_2(0.55) \approx -0.862, \text{ 所以 } 0.55 \times (-0.862) \approx -0.4741$$

最终：

$$Entropy(S) \approx -(-0.5184 - 0.4741) = 0.9925$$

2. 计算所有特征的信息增益

特征列表：年龄、服务时间、月消费、投诉次数、非保险费

信息增益公式：

$$InfoGain(S, \text{特征}) = Entropy(S) - \sum_{v \in \text{特征取值}} \frac{N_v}{N} \times Entropy(S_v)$$

其中 S_v 是特征取 v 时的子集， N_v 是子集样本数

特征：年龄

年龄取值：青年、中年、老年

年龄	样本数	续签数	不续签数
青年	7	2	5
中年	7	5	2
老年	6	3	3

青年子集熵 $Entropy(\text{青年}) = -(\frac{2}{7}\log_2(\frac{2}{7}) + \frac{5}{7}\log_2(\frac{5}{7})) \approx 0.971$
中年子集熵 $Entropy(\text{中年}) = -(\frac{5}{7}\log_2(\frac{5}{7}) + \frac{2}{7}\log_2(\frac{2}{7})) \approx 0.863$
老年子集熵 $Entropy(\text{老年}) = -(\frac{3}{6}\log_2(\frac{3}{6}) + \frac{3}{6}\log_2(\frac{3}{6})) = 1.0$

信息增益计算：
 $InfoGain(\text{年龄}) = 0.9925 - (\frac{7}{20} \times 0.971 + \frac{7}{20} \times 0.863 + \frac{6}{20} \times 1.0)$
 $= 0.9925 - (0.33985 + 0.30205 + 0.3)$
 $= 0.9925 - 0.9419 \approx 0.0506$

特征：服务时间

服务时间取值：短、中、长

服务时间	样本数	续签数	不续签数
短	6	1	5
中	7	5	2
长	7	3	4

短子集熵 $Entropy(\text{短}) = -(\frac{1}{6}\log_2(\frac{1}{6}) + \frac{5}{6}\log_2(\frac{5}{6})) \approx 0.65$
中子集熵 $Entropy(\text{中}) = -(\frac{5}{7}\log_2(\frac{5}{7}) + \frac{2}{7}\log_2(\frac{2}{7})) \approx 0.863$

长子集熵 $Entropy(长) = -\left(\frac{3}{7}\log_2\left(\frac{3}{7}\right) + \frac{4}{7}\log_2\left(\frac{4}{7}\right)\right) \approx 0.985$

信息增益计算:
 $InfoGain(服务时间) = 0.9925 - \left(\frac{6}{20} \times 0.65 + \frac{7}{20} \times 0.863 + \frac{7}{20} \times 0.985\right)$
 $= 0.9925 - (0.195 + 0.30205 + 0.34475)$
 $= 0.9925 - 0.8418 \approx 0.1507$

特征：月消费

月消费取值：低、中、高

月消费	样本数	续签数	不续签数
低	4	0	4
中	7	3	4
高	9	6	3

低子集熵 $Entropy(低) = -\left(\frac{0}{4}\log_2\left(\frac{0}{4}\right) + \frac{4}{4}\log_2\left(\frac{4}{4}\right)\right) = 0$

中子集熵 $Entropy(中) = -\left(\frac{3}{7}\log_2\left(\frac{3}{7}\right) + \frac{4}{7}\log_2\left(\frac{4}{7}\right)\right) \approx 0.985$

高子集熵 $Entropy(高) = -\left(\frac{6}{9}\log_2\left(\frac{6}{9}\right) + \frac{3}{9}\log_2\left(\frac{3}{9}\right)\right) \approx 0.918$

信息增益计算:
 $InfoGain(月消费) = 0.9925 - \left(\frac{4}{20} \times 0 + \frac{7}{20} \times 0.985 + \frac{9}{20} \times 0.918\right)$
 $= 0.9925 - (0 + 0.34475 + 0.4131)$
 $= 0.9925 - 0.75785 \approx 0.23465$

特征：投诉次数

投诉次数取值：0、1、≥2

投诉次数	样本数	续签数	不续签数
0	10	6	4

投诉次数	样本数	续签数	不续签数
1	6	3	3
≥2	4	0	4

0子集熵 $Entropy(0) = -\left(\frac{6}{10}\log_2\left(\frac{6}{10}\right) + \frac{4}{10}\log_2\left(\frac{4}{10}\right)\right) \approx 0.971$

1子集熵 $Entropy(1) = -\left(\frac{3}{6}\log_2\left(\frac{3}{6}\right) + \frac{3}{6}\log_2\left(\frac{3}{6}\right)\right) = 1.0$

≥2子集熵 $Entropy(\geq 2) = -\left(\frac{0}{4}\log_2\left(\frac{0}{4}\right) + \frac{4}{4}\log_2\left(\frac{4}{4}\right)\right) = 0$

信息增益计算:

$InfoGain(\text{投诉次数}) = 0.9925 - \left(\frac{10}{20} \times 0.971 + \frac{6}{20} \times 1.0 + \frac{4}{20} \times 0\right)$
 $= 0.9925 - (0.4855 + 0.3 + 0)$
 $= 0.9925 - 0.7855 \approx 0.207$

特征：非保险费

非保险费取值：基础、高级

非保险费	样本数	续签数	不续签数
基础	10	3	7
高级	10	6	4

基础子集熵 $Entropy(\text{基础}) = -\left(\frac{3}{10}\log_2\left(\frac{3}{10}\right) + \frac{7}{10}\log_2\left(\frac{7}{10}\right)\right) \approx 0.881$

高级子集熵 $Entropy(\text{高级}) = -\left(\frac{6}{10}\log_2\left(\frac{6}{10}\right) + \frac{4}{10}\log_2\left(\frac{4}{10}\right)\right) \approx 0.971$

信息增益计算:

$InfoGain(\text{非保险费}) = 0.9925 - \left(\frac{10}{20} \times 0.881 + \frac{10}{20} \times 0.971\right)$
 $= 0.9925 - (0.4405 + 0.4855)$
 $= 0.9925 - 0.926 \approx 0.0665$

3. 选择最优划分特征

特征	信息增益
年龄	0.0506
服务时间	0.1507
月消费	0.23465
投诉次数	0.207
非保险费	0.0665

月消费的信息增益最大 (0.23465) ， 所以选择月消费作为根节点的划分特征。

第 2 层：基于月消费划分

分支：月消费=低 (样本数=4)

该子集全部为不续签样本， 已为纯节点， 无需继续划分。

决策：不续签

分支：月消费=中 (样本数=7)

1. 计算子集的信息熵

续签数 = 3， 不续签数 = 4

$$Entropy(S) = - \left(\frac{3}{7} \log_2 \left(\frac{3}{7} \right) + \frac{4}{7} \log_2 \left(\frac{4}{7} \right) \right) \approx 0.985$$

2. 计算剩余特征的信息增益 (排除已使用的月消费)

特征	信息增益
年龄	0.276
服务时间	0.019
投诉次数	0.151
非保险费	0.019

年龄的信息增益最大 (0.276) , 所以选择年龄作为该节点的划分特征。

第 3 层：基于年龄划分

分支：年龄=青年 (样本数=3)

该子集全部为不续签样本，已为纯节点，无需继续划分。

决策：不续签

分支：年龄=中年 (样本数=2)

该子集全部为不续签样本，已为纯节点，无需继续划分。

决策：不续签

分支：年龄=老年 (样本数=2)

该子集全部为续签样本，已为纯节点，无需继续划分。

决策：续签

分支：月消费=高 (样本数=9)

1. 计算子集的信息熵

续签数 = 6, 不续签数 = 3

$Entropy(S) = -(\frac{6}{9}\log_2(\frac{6}{9}) + \frac{3}{9}\log_2(\frac{3}{9})) \approx 0.918$

2. 计算剩余特征的信息增益 (排除已使用的月消费)

特征	信息增益
年龄	0.011
服务时间	0.011
投诉次数	0.439
非保险费	0.011

投诉次数的信息增益最大 (0.439) , 所以选择投诉次数作为该节点的划分特征。

第 3 层：基于投诉次数划分

分支：投诉次数=0 (样本数=5)

该子集全部为续签样本, 已为纯节点, 无需继续划分。

决策：续签

分支：投诉次数=1 (样本数=3)

该子集全部为续签样本，已为纯节点，无需继续划分。

决策：续签

分支：投诉次数 ≥ 2 (样本数=1)

该子集全部为不续签样本，已为纯节点，无需继续划分。

决策：不续签

最终决策树结构

根节点：月消费

月消费=低 $\rightarrow$ 决策：不续签

月消费=中 $\rightarrow$ 划分特征：年龄

年龄=青年 $\rightarrow$ 决策：不续签

年龄=中年 $\rightarrow$ 决策：不续签

年龄=老年 → 决策: 续签

月消费=高 → 划分特征: 投诉次数

投诉次数=0 → 决策: 续签

投诉次数=1 → 决策: 续签

投诉次数≥2 → 决策: 不续签

信息增益可视化

